

From Sparse Solutions of Systems of Equations to Sparse Modeling of Images

Minxuan Wang

2016 年 5 月 17 日

线性方程稀疏解

$$\min_x J(x) \text{ s.t. } b = Ax \quad A \in \mathbb{R}^{n \times m}$$

将 $J(x)$ 理解为稀疏性(*sparsity*), 问题转化成线性方程的最稀疏解, 使用向量中非零值的个数来描述向量的稀疏性.


$$\|x\|_0 = \#\{i : x_i \neq 0\}$$

将矩阵 A 的列看作字典原子, b 是原信号向量, x 表示 A 中原子的线性组合, 要求这个线性组合为最稀疏的

优化中的问题

NP-Hard 非凸问题，难以有效求解，但是假如A中的列不相关，*sparsity*(0范数问题)将会等价于1范数问题(凸函数)。另外对于某些种类的问题GA算法能够得到最稀疏解。

$$\|x\|_p = \left(\sum_i |x_i|^p \right)^{1/p}$$



最稀疏解的唯一性问题

什么时候存在最稀疏解？

*spark*定义: *The spark of a given matrix A is the smallest number of columns from A that are linearly dependent.*

$$\begin{bmatrix} 1 & 0 & 0 & 0 & 1 \\ 0 & 1 & 0 & 0 & 1 \\ 0 & 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 1 & 0 \end{bmatrix}$$

Rank=4 Spark=3

最稀疏解的唯一性问题

定理: *If a system of linear equations $Ax = b$ has a solution x obeying $\|x\|_0 < \text{spark}(A)/2$, this solution is necessarily the sparsest possible.*

证明: 若 $Ax=0$, 那么 $\|x\|_0 \geq \text{spark}(A)$, 因为 Ax 表示 A 中某几列的线性组合为 0, 说明 A 中这几列线性相关。故大于 $\text{spark}(A)$ 考虑另外一个解 y , 有 $A(x-y)=0$, 那么

$$\|x\|_0 + \|y\|_0 \geq \|x - y\|_0 \geq \text{spark}(A)$$

因为 $\|x\|_0 < \text{spark}(A)/2$ 那么另外一个必然大于 $\text{spark}(A)/2$ 所以没有比这个解更稀疏的解。

最稀疏解的唯一性问题

通常直接计算spark的比较困难。所以可以通过Mutual Coherence来刻画最稀疏解的唯一性。

定义: *The mutual coherence of a given matrix A is the largest absolute normalized inner product between different columns from A . Denoting the k th column in A by a_k , the mutual coherence is given by*

$$\mu(A) = \max_{1 \leq k, j \leq m, k \neq j} \frac{|a_k^T a_j|}{\|a_k\|_2 \cdot \|a_j\|_2}$$

酉矩阵, $\mu(A)=0$

最稀疏解的唯一性问题

引理: *For any matrix $A \in \mathbb{R}^{n \times m}$, the following relationship holds:*

$$\text{spark}(A) \geq 1 + \frac{1}{\mu(A)}$$

证明: 首先normalize A矩阵的列向量, 得到 \tilde{A} spark μ 都不变, Gram Matrix $G = \tilde{A}^T \tilde{A}$ 满足:

$$\{G_{k,k} = 1 : 1 \leq k \leq m\} \quad \{|G_{k,j}| \leq \mu : 1 \leq k, j \leq m, k \neq j\}$$

从 \tilde{A} 中选取 p 列, 并计算子Gram Matrix, 如果此子矩阵是对角占优矩阵($\sum_{j \neq i} |G_{i,j}| < |G_{i,i}|$), 那么此矩阵是正定的(非奇异的), 故A中这 p 列线性无关。所以, 如果有 $p < 1 + 1/\mu$ 那么子矩阵就是正定的并且必然存在一个 p 满足介于 $[1/\mu, 1 + 1/\mu]$ 之间(p 任意取, 可以取到 $1 + 1/\mu$ 的下取整, 而 $1 + 1/\mu$ 的下取整大于 $1/\mu$)所以存在 p 使 $p + 1 \geq 1 + 1/\mu$, 那么 $\text{spark}(A) \geq 1 + 1/\mu$

求解最稀疏解

可以使用BP算法, 求解1范数来代替0范数(凸优化问题)。

另外可以使用GA算法, 例如MP, OMP。

目标: 解优化 $P_0 : \min_x \|x\|_0 \text{ s.t. } Ax = b$ 参数: A, b , 错误阈值 ϵ_0

初始化: $k = 0, x^0 = 0, r^0 = b - Ax^0 = b, S^0 = \emptyset$

迭代: (1) 计算误差 $\epsilon(j) = \min_{z_j} \|a_j z_j - r^{k-1}\|_2^2$ 最优解

为 $z_j^* = a_j^T r^{k-1} / \|a_j\|_2^2$

(2) 找到最小的误差 $\epsilon(j_0)$ 并将 j_0 保存进 S , $S^k = S^{k-1} \cup \{j_0\}$

(3) 计算 x^k , 根据 S^k 最小化 $\|Ax - b\|_2^2$

(4) 更新残差 $r^k = b - Ax^k$

(5) 残差小于阈值 ϵ_0 停止, 最优解为 x^k

可以证明如果满足 $\|x\|_0 < \frac{1}{2}(1 + \frac{1}{\mu(A)})$ 则GA能收敛到最稀疏解

形态学成分分析MCA

假设将一副图像，考虑为两种信号的叠加。通过不同的稀疏模型来分离两种信号。


$$\text{优化问题: } \min_{x_1, x_2} \|x_1\|_0 + \|x_2\|_0 \text{ s.t. } \|y - A_1x_1 - A_2x_2\|_2^2 \leq \epsilon_1^2 + \epsilon_2^2$$



Original image



Cartoon part



Texture part

字典学习K-SVD

之前的介绍中字典都是固定的，K-SVD算法通过样本学习来更新字典。

目标：找到最佳的字典来表示样本 $\{y_i\}_{i=1}^N$, 优化目标：

$$\min_{D, X} \{\|Y - DX\|_F^2\} \text{ s.t. } \forall i, \|x_i\|_0 < T_0$$

设置 $D^0 \in \mathbb{R}^{n \times K}, J=1$

使用之前的算法对每一个 y_i 计算 $x_i, i=1, 2, \dots, N$

$$\min_{x_i} \{\|y_i - Dx_i\|_2^2\} \text{ s.t. } \|x_i\|_0 \leq T_0$$

对于

$$\begin{aligned} \|Y - DX\|_F^2 &= \|Y - \sum_1^K d_j x_T^j\|_F^2 = \\ \|(Y - \sum_{j \neq k} d_j x_T^j) - d_k x_T^k\|_F^2 &= \|E_k - d_k x_T^k\|_F^2 \end{aligned}$$

字典学习K-SVD

做一个变换: $\|E_k \Omega_k - d_k x_T^k \Omega_k\|_F^2 = \|E_R - d_k x_R^k\|_F^2$

使用奇异值分解SVD, 得到 $E_k^R = U \Delta V^T$

$d = U, x = V$

K-SVD应用

很容易理解,使用K-SVD可以得到图像的稀疏表示, 只需存储码表以及字典就可以保存图像的信息。实现了图像压缩。

另外K-SVD可以应用于图像降噪.原理是降维是一种有效的去除噪声的方法。可以假设无噪声图像可以很好得使用稀疏表示, 当对一个噪声图像进行稀疏表示时, 噪声部分随着降维被滤掉。

去噪问题要优化的问题是

$$\tilde{\alpha} = \operatorname{argmin}_{\alpha} \|\alpha_0\| \quad s.t. \quad \|D\alpha - y\|_2^2 \leq T$$

改写成罚函数的形式: $\tilde{\alpha} = \operatorname{argmin}_{\alpha} \|D\alpha - y\|_2^2 + \mu \|\alpha_0\|$

当图像比较大的时候, K-SVD字典学习会很慢, 有两种方法来处理, 其中之一是将大图像分解成一块一块的小图像来处理
如 $\sqrt{n} \times \sqrt{n}$

罚函数变为: $\{\widetilde{\alpha}_{ij}, \widetilde{X}\} =$

$$\operatorname{argmin}_{\{\alpha_{ij}, X\}} \lambda \|X - Y\|_2^2 + \sum_{ij} \mu_{ij} \|\alpha_{ij}\|_0 + \sum_{ij} \|D\alpha_{ij} - R_{ij}X\|_2^2$$

将D看作已知, 然后 $Y=X$, 可以得到所有的优化解 $\widetilde{\alpha}$ 类似之前的K-SVD操作更新D, 并解出X, 优化目标

$$\widetilde{X} = \operatorname{argmin}_X \lambda \|X - Y\|_2^2 + \sum_{ij} \|D\alpha_{ij} - R_{ij}\|_2^2 X^2$$